

LLM Evaluation



Accuracy



Latency



Cost

Hal
Oct 25, 2025


Agenda

1. Classic benchmarks
2. Trending
3. Performance evaluation
4. RLHF

Agenda

1. Classic benchmarks
2. Trending
3. Performance evaluation
4. RLHF

Classic benchmarks



Category	Benchmark	Llama 3 8B			Llama 3 70B			Llama 3 405B			Claude 3.5 Sonnet
		Gemma 2 9B	Mistral 7B	Mistral 8x22B	GPT 3.5 Turbo	Nemotron 4 340B	GPT-4o	GPT-4o	GPT-4o	GPT-4o	
General	MMLU (Zero-shot)	68.4	72.3 [△]	61.1	83.6	76.9	70.7	87.3	82.6	85.1	89.9
	MMLU (Few-shot, CoT)	73.0	72.3 [△]	60.5	86.0	79.0	60.8	88.6	78.7 [△]	85.4	88.3
	MMLU-Pro (Llama, CoT)	48.3	—	36.9	66.4	56.3	40.2	73.3	62.7	64.8	77.0
	IFEval	80.4	73.6	57.6	87.5	72.7	60.9	88.6	85.1	84.3	85.6
Code	HumanEval (Zero-shot)	72.6	54.3	40.2	80.5	75.6	68.0	89.0	73.2	86.6	90.2
	MBPP EvalPlus (Zero-shot)	72.8	71.7	49.5	86.0	78.6	82.0	88.6	72.8	83.6	87.8
Math	GSMMK (Zero-shot, CoT)	84.5	76.7	53.2	95.1	88.2	81.8	96.8	92.3 [△]	94.2	96.1
	MATH (Zero-shot, CoT)	51.9	44.3	13.0	68.0	54.1	43.1	73.8	41.1	64.5	76.6
Reasoning	ARC Challenge (Zero-shot)	83.4	87.6	74.2	94.8	88.7	83.7	96.9	94.6	96.4	96.7
	GPQA (Zero-shot, CoT)	32.8	—	28.8	46.7	33.3	30.8	51.1	—	41.4	53.6
Tool use	BFCL	76.1	—	60.4	84.8	—	85.9	88.5	86.5	88.3	90.2
	Nexus	38.5	30.0	24.7	56.7	48.5	37.2	58.7	—	50.3	45.7
Long context	ZeroSCROLLS/QuALITY	81.0	—	—	90.5	—	—	95.2	—	90.5	90.5
	InfiniteBench/Eu.MC	66.1	—	—	78.2	—	—	83.4	—	72.1	82.5
Multilingual	NIH/Multi-needle	98.8	—	—	97.5	—	—	98.1	—	100.0	100.0
	MGSM (Zero-shot, CoT)	88.9	53.2	29.9	86.9	71.1	51.4	91.6	—	85.9	90.5

Table 2 Performance of finetuned Llama 3 models on key benchmark evaluations. The table compares the performance of the 8B, 70B, and 405B versions of Llama 3 with that of competing models. We **boldface** the best-performing model in each of three model-size equivalence classes. [△]Results obtained using 5-shot prompting (no CoT). [△]Results obtained without CoT. [△]Results obtained using zero-shot prompting.

Llama 4 Maverick instruction-tuned benchmarks												
Benchmarks	Llama 4 Maverick		Gemini 2.0 Flash		DeepSeek V3		GPT-4o		English		Chinese	
	overall	text formula table order	overall	text formula table order	overall	text formula table order	overall	text formula table order	overall	text formula table order	overall	text formula table order
Pipeline Models												
Accuracy (EM)	0.356	0.352	0.465	0.258	0.35	0.44	0.44	0.604	0.367	0.351	0.296	0.085
Cost per 1M input tokens (USD)	0.085	0.374	0.609	0.116	0.497	0.293	0.688	0.678	0.329	0.191	0.105	
Input Tokens	0.306	0.346	0.243	0.108	0.364	0.381	0.454	0.32	0.30	0.162	0.072	
Model Size	0.313	0.313	0.166	0.197	0.244	0.111	0.581	0.15	0.136	0.154	0.062	
Input Tokens	0.295	0.164	0.094	0.263	0.179	0.464	0.168	0.243	0.152	0.073		
Model Size	0.295	0.162	0.077	0.223	0.136	0.535	0.111	0.11				
End-to-end Models												
Accuracy (EM)	0.452	0.365	0.488	0.572	0.382	0.673	0.998	0.941	1.00	0.934	0.493	0.262
Cost per 1M input tokens (USD)	0.262	0.753	0.729	0.227	0.816	0.838	0.997	0.907	0.522	0.44	0.353	
Input Tokens	0.543	0.547	0.317	0.443	0.29	0.701	0.955	0.228	0.316	0.151		
Model Size	0.376	0.598	0.138	0.399	0.243	0.5	0.627	0.226	0.326	0.097		
Input Tokens	0.455	0.608	0.145	0.469	0.293	0.695	0.652	0.277	0.287	0.189		
Model Size	0.360	0.459	0.141	0.411	0.315	0.528	0.52	0.28	0.238	0.112		
Input Tokens	0.447	0.269	0.126	0.349	0.296	0.716	0.162	0.263	0.233	0.144		
Model Size	0.425	0.234	0.128	0.399	0.409	0.606	0.329	0.251	0.218	0.117		
Input Tokens	0.38	0.279	0.095	0.296	0.21	0.533	0.282	0.161	0.214	0.092		
Model Size	0.315	0.341	0.106	0.261	0.18	0.434	0.262	0.168	0.182	0.137		
Input Tokens	0.320	0.166	0.182	0.261	0.229	0.468	0.160	0.261	0.148	0.055		
Model Size	0.356	0.13	0.049	0.212	0.168	0.439	0.119	0.121	0.133	0.045		
Input Tokens	0.273	0.15	0.066	0.238	0.115	0.506	0.209	0.122	0.125	0.032		
Model Size	0.329	0.099	0.084	0.18	0.066	0.416	0.092	0.067				
DeepSeek-OCR (end2end)												
Accuracy (EM)	0.386	0.373	0.469	0.422	0.283	0.361	0.307	0.635	0.266	0.236	0.221	0.142
Cost per 1M input tokens (USD)	0.374	0.342	0.373	0.242	0.125	0.284	0.24	0.53	0.159	0.205	0.137	0.094
Input Tokens	0.267	0.165	0.064	0.24	0.205	0.479	0.1	0.181	0.138	0.054		
Model Size	0.277	0.152	0.067	0.208	0.143	0.461	0.104	0.123	0.127	0.043		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Model Size	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.105	0.123	0.045		
Input Tokens	0.269	0.134	0.062	0.1								

Classic benchmarks

World Knowledge / General Ability:

- MMLU
- MMLU Pro
- Multilingual MMLU
- GPQA Diamond
- PopQA
- TruthfulQA

Math / Reasoning

- GSM8K
- MATH-500
- AIME 2024
- MMLU Pro
- BBH
- DROP

Instruction Following / Helpfulness

- IFEval
- AlpacaEval v2

Coding / Software Engineering

- SWE-bench Verified
- LiveCodeBench / Codeforces

Agenda

1. Classic benchmarks
2. Trending
3. Performance evaluation
4. RLHF

Leaderboard

 Text

 9 days ago

Rank (UB) ↑	Model ↓	Score ↓	Votes ↓
1	 gemini-2.5-pro	1451	54,087
1	 claude-opus-4-1-20250805-thi...	1447	21,306
1	 claude-sonnet-4-5-20250929-t...	1445	6,287
1	 gpt-4.5-preview-2025-02-27	1441	14,644
2	 chatgpt-4o-latest-20250326	1440	40,013
2	 o3-2025-04-16	1440	51,293
2	 claude-sonnet-4-5-20250929	1438	6,144
2	 gpt-5-high	1437	23,580
2	 claude-opus-4-1-20250805	1437	33,298
3	 qwen3-max-preview	1434	18,078

[View all](#)

 WebDev

 5 days ago

Rank (UB) ↑	Model ↓	Score ↓	Votes ↓
1	 GPT-5 (high)	1478	5,848
1	 Claude Opus 4.1 thinking-16k...	1472	5,312
1	 Claude Opus 4.1 (20250805)	1462	5,582
4	 Claude Sonnet 4.5 (thinking ...	1421	1,337
4	 Gemini-2.5-Pro	1401	11,022
4	 GLM-4.6	1398	5,442
4	 DeepSeek-R1-0528	1394	4,800
5	 Claude Sonnet 4.5	1385	4,127
6	 Claude Opus 4 (20250514)	1384	9,238
6	 GLM-4.5	1381	4,360

[View all](#)


Context window

Context Window

Context Window: Tokens Limit; Higher is better



Artificial Analysis




TTFT

Time to First Answer Token


Seconds to First Token Received; Lower is better

■ 'Thinking' time (reasoning models, where applicable) ■ Input processing time


Artificial Analysis



Traffic



Marketshare%



1.	x-ai	1.41T	29.7%
2.	google	902B	19.0%
3.	anthropic	856B	18.0%
4.	openai	519B	10.9%
5.	deepseek	311B	6.5%

6.	qwen	240B	5.0%
7.	z-ai	142B	3.0%
8.	tngtech	101B	2.1%
9.	meta-llama	91B	1.9%
10.	others	183B	3.8%

Price vs Performance

Intelligence vs. Price

Artificial Analysis Intelligence Index; Price: USD per 1M Tokens

Most attractive quadrant

Databricks



Agenda

1. Classic benchmarks
2. Trending
3. Performance evaluation
4. RLHF

Performance evaluation

Accuracy

- Pass@1 / Pass@K
- BLEU / ROUGE / exact-match F1
- Faithfulness / Groundedness / Hallucination Rate
- Instruction Following / Compliance
- Helpfulness / Preference Scores / Elo-style Arena Score
- Safety / Toxicity / Refusal Appropriateness


Latency

- Time to First Token (TTFT)
- Time to Last Token / Total Response Time
- Tokens per Second
- p50 / p90 / p99 Latency

Agenda

1. Classic benchmarks
2. Trending
3. Performance evaluation
4. RLHF

Reinforcement learning from human feedback (RLHF)



Thanks!

QA